C++プログラミング II

第 12 回 string と正規表現

岡本秀輔

成蹊大学理工学部

string と探索アルゴリズム

std::string と探索アルゴリズム

- string は添字と std::string::npos を使用する
- コンテナではないが類似メンバ関数を持つ
  - begin, end, size, clear, swap push_back, pop_back, insert, など
- STL アルゴリズムが適用可能
  - begin, end で得たイテレータに互換性がある
  - ランダム・イテレータ
- 独自のメンバ関数で高速な処理を実現

探索対象	std::string	STL アルゴリズム
最初に現れる要素	find	find
最後に現れる要素	rfind	find と逆イテレータ
最初に現れる部分範囲	find	search
最後に現れる部分範囲	rfind	find_end
部分範囲の高々1 つが同じ最初	find_first_of	find_first_of
部分範囲の高々1 つが同じ最後	find_last_of	find_first_of と逆イテレータ
最初に現れる n 個連続部分		search_n

std::find とメンバ関数 find

- 1 文字を探す
- メンバ関数 find は添字を返す

```
int main()
{
    string t{"I am running now."};

    // STL アルゴリズム
    auto it {std::find(t.begin(), t.end(), 'n')};
    if (it != t.end())
        cout <<"found at "<< it-t.begin() <<"\n";

    // string メンバ関数
    size_t idx { t.find('n') };
    if (idx != string::npos)
        cout <<"found at "<< idx <<"\n";
}
```

std::find とメンバ関数 rfind

- 後ろから 1 文字を探す (reverse の r)
- 逆イテレータよりもメンバ関数を使用した方が良い

```
int main()
{
    string t {"I am running now."};

    // STL アルゴリズム
    auto it {std::find(t.rbegin(), t.rend(), 'n')};
    if (it != t.rend())
        cout << "found at "
            << (t.size()-1) - (it-t.rbegin()) <<"\n";

    // メンバ関数
    size_t idx { t.rfind('n') };
    if (idx != string::npos)
        cout <<"found at " << idx <<"\n";
}
```

std::search とメンバ関数 find

- std::search は汎用なので指定が冗長にみえる

```
int main()
{
    string t{"I am running now."}, w{"ing"};

    // STL アルゴリズム
    auto it {std::search(t.begin(), t.end(),
                         w.begin(), w.end()) };
    if (it != t.end())
        cout <<"found at "<< it-t.begin()<<"\n";

    // メンバ関数
    size_t p { t.find(w) };
    if (p != string::npos)
        cout <<"found at "<< p <<"\n";
}
```

std::find_end とメンバ関数 rfind

- t の後ろ側から部分範囲 w を探す

```
int main()
{
    string t{"NumPy is a Python library"}, w{"Py"};

    // STL アルゴリズム
    auto it {std::find_end(t.begin(), t.end(),
                           w.begin(), w.end()) };
    if (it != t.end())
        cout <<"found at " << it-t.begin() <<"\n";

    // メンバ関数
    size_t p { t.rfind(w) };
    if (p != string::npos)
        cout <<"found at " << p <<"\n";
}
```

std::find_first_of とメンバ関数 find_first_of

- t から s のどれかの文字を探す

```
int main(){
    string t{"hello, world"}, s{"orz"};

    // STL アルゴリズム
    auto it { std::find_first_of(
                  t.begin(), t.end(),
                  s.begin(), s.end()) };
    if (it != t.end())
        cout << it-t.begin() <<":"<< *it <<"\n";

    // メンバ関数
    size_t pos = t.find_first_of(s);
    if (pos != string::npos)
        cout << pos <<":"<< t[pos] <<"\n";
}
```

STL アルゴリズムによる単語抽出

- 区切り文字を指定して単語を抽出
- STL アルゴリズムのみで実装できるが煩雑

```
string t{" Hooray, it's nice! I like it."},
       d{".,?! "}; // delimiters
const auto tb{t.begin()}, te{t.end()};
const auto db{d.begin()}, de{d.end()};
auto head {tb};
auto tail {std::find_first_of(head, te, db, de)};
while (tail != te) {
   if (head != tail) {
      string sub;
      std::copy(head, tail, std::back_inserter(sub));
      std::cout << sub <<"\n";
   }
   head = std::next(tail); // 区切り文字の次から
   tail = std::find_first_of(head, te, db, de);
}
```

string メンバ関数による単語抽出

- pos2 string::find_first_of(str, pos1)
  - pos2:見つけた文字位置
  - str:探したい文字群, pos1:調べる先頭位置
- 前のスライドと同じ内容

```
string t{" Hooray, it's nice! I like it."},
       delim{".,?! "};
size_t head {0};
size_t tail { t.find_first_of(delim, head) };
while (tail != string::npos) {
   if (head != tail)
      cout << t.substr(head, tail-head) <<"\n";
   head = ++tail; // 区切り文字の次から
   tail = t.find_first_of(delim, head);
}
```

正規表現

正規表現とは

- 文字列のグループ（集合）を指定する方法
  - 複数の文字列をグループ化する
  - 文字列を探す際に条件を指定できる
- 文字の指定の例
  - a や b などのそのままの 1 文字
  - アルファベットに属する 1 文字
  - 数字 1 文字
  - ある範囲の 1 文字 (0〜7 や a〜z など)
  - 改行文字以外の任意の 1 文字 (どれでも良い)
- 特定の文字に特殊な意味を持たせる
  - ^ $ \ . * + ? ( ) [ ] { } | は特殊な意味を持つ
  - \n や\w など、バックスラッシュ＋文字の形で、特殊な意味を表したり、逆に特殊な意味を無効化したりする。

std::ECMAScript 構文

- 正規表現にはいろいろな種類がある
- C++11 の正規表現は JavaScript 言語の規格に沿う
- その他の種類の正規表現もオプションにより指定可能
- 単純な例

正規表現	マッチする文字列	備考
ab	ab	文字列そのものの指定
a|b	a、b	二者の選択
a*	a、aa、aaa	a の 0 回以上の繰り返し
a(a|b)*	a、aa、ab、aaa、aab、aababa、···	先頭が a で後に a か b が 0 回以上続く
(a|b)*c	c, ac, bc、aac、abc、···	a と b が 0 回以上続き c で終わる

正規表現ルール 1

- 1 文字の指定

指定	マッチする文字
\t	水平タブ
\n	改行文字 (LF:Line Feed, 0xA)
\r	キャリッジリターン文字 (CR:Carriage Return, 0xD)
\0	ヌル文字
.	改行文字 (\r や\n) 以外の１文字
\d	10 進数の数字 (digit)
\D	10 進数の数字以外の文字 (大文字は補集合)
\s	ホワイトスペース (改行を含む)
\S	ホワイトスペース以外の文字
\w	英数字または下線文字
\W	英数字でも下線文字でもない文字

正規表現ルール2

- 範囲指定の1文字
  - 角括弧を使ってマッチする1文字のクラスを指定
  - [^範囲] は補集合の意味

指定	マッチする文字
[abc]	abc のどれかの1文字
[a-z]	a から z のどれかの1文字
[\t\n\r]	スペース文字,\t,\n,\r のどれか1文字
[^abc]	abc 以外の1文字

- 繰り返しの指定

指定	マッチする文字
*	0 またはそれ以上の繰り返し
+	1回以上の繰り返し
?	あってもなくても良い (0 or 1)
{x}	x を整数として, ちょうど x 回の繰り返し
{x,}	x を整数として, x 回以上の繰り返し
{x,y}	x,y を整数として、x 回以上 y 回以下の繰り返し

正規表現ルール3

- グループ化
  - グループを * などの繰り返しの対象に使用可能
  - 必要ならばマッチしたサブパターンを後で利用可能

(サブパターン)	グループ化して後で利用
(?:サブパターン)	グループ化するのみ

- 表明（アサーション）
  - パターンの前後の条件を指定する

^	続くパターンは行頭 (補集合ではない)
$	これの前のパターンは行末
\b	単語の区切り

- 二者択一

|	両側の二つのパターンどちらか

正規表現の例

正規表現	マッチする文字
a.*b	ab, anb, accab など (先頭 a 末尾 b)
a{3}	aaa, ちょうど 3 文字の a
a{3,5}	aaa, aaaa, aaaaa のどれか
[a-zA-Z_][\w]*	c++の変数/関数などの名前
<[a-z]+>.*</[a-z]+>	XML(html) の開きタグと閉じタグ
<([a-z]+)>.*</\1>	対応する開きタグと閉じタグ
[^xyz]	xyz 以外の文字
^xyz	行頭にある xyz
xyz$	行末にある xyz
\bxyz	文字列の途中ではない xyz
abc|xyz	abc または xyz のどちらか
\b[\w]+\.(?:\w){3}\b	3 文字拡張子の英数字ファイル名

Raw文字列

Raw 文字列

- C++の文字列リテラルでは\文字が特殊な意味を持つ
- 正規表現の\w を指定するには"\\w"と書く必要がある
  - 複雑な正規表現は\が多数並ぶ

Raw 文字列とは (Raw:生の, 加工していない):

- 指定した文字をそのまま扱う別の文字列リテラル
- 改行もそのまま文字列の一部となる
- R"(文字列)"とする。
  - つまり R"(と)"で文字列をくくる。
- 文字列にラベルを付けても良い
  - R"ラベル (文字列) ラベル"の形式
  - エディタで検索しやすくなる

```
"[\\d\\w]*"                          // 通常の文字列指定
R"([\d\w]*)"                           // Raw 文字列
R"var([a-zA-Z_][\d\w]*)var"            // var がラベル
```

C++11の正規表現

概要

- <regex>ヘッダファイル
- 正規表現指定クラス: std::regex
  - 例: std::regex r{"a[bc]c"};
- パターンを探す関数
  - 対象全体に対するマッチ：
    - std::regex_match(s, r)　: r がマッチしたか？
    - std::regex_match(s, m, r): マッチの詳細を m に
  - マッチの探索（部分一致）：
    - std::regex_search(s, r)　: r のマッチを探す
    - std::regex_search(s, m, r): マッチの詳細を m に

```
#include <iostream>
#include <regex>
int main() {
   std::string src{"abc"};   // 検索対象
   std::regex reg{"a[bc]c"}; // 正規表現
   std::cout << std::boolalpha
   << std::regex_match(src, reg) <<"\n"; // true
}
```

regex_match() と regex_search()

- マッチの有無を bool 型で返す
- regex_match() は全体への一致を求める
- regex_search() は部分一致も許容する

```
std::vector<string> lst // 検索対象文字列群
{"ac", "aaac", " aac ", "akb", "ac ccc", "anc "};
std::regex r{"a.*c"}; // 正規表現

for (auto& s : lst)
   if (std::regex_match(s, r)) // 全体一致
      cout << s <<", ";
cout <<"\n"; // ac, aaac, ac ccc,

for (auto& s : lst)
   if (std::regex_search(s, r)) // 部分一致
      cout << s <<", ";
cout <<"\n"; // ac, aaac,  aac , ac ccc, anc ,
```

改行を含む例

- regex_search() は部分一致を行う
- regex_match() でも正規表現に周辺のパターンを含めれば同じ (改行文字は特別扱いが必要)

```
string s{" ab\ncdefg "}; // 検索対象は改行を含む

std::regex r1{"cde"};
if (std::regex_search(s, r1)) // true
    cout <<"found1\n";

std::regex r2{R"(.*cde.*)"};
if (std::regex_match(s, r2))  // false
    cout <<"found2\n";

std::regex r3{R"((.|\n)*cde(.|\n)*)"};
if (std::regex_match(s, r3))  // true
    cout <<"found3\n";
```

結果オブジェクト

- std::smatch オブジェクトでマッチの詳細が得られる

```
void test(string s, string reg) {
    cout << s <<", "<< reg <<":\n";
    std::regex r{reg};
    std::smatch m;
    if (std::regex_match (s, m, r))
        cout <<"   match : m[0]="<< m[0] <<"\n";
    if (std::regex_search(s, m, r))
        cout <<"   search: m[0]="<< m[0] <<"\n";
    // string で結果を得るには m[0].str()
}

int main() {
    test("get_X", "get|get_X"); // get or get_X
    test("get_XY","get|get_X");
    test("get_X", "get.*");
}
```

出力結果

- 同一の正規表現でも match と search で結果が異なる
- search は.*に対して最大一致をとる

```
get_X, get|get_X:
   match : m[0]=get_X
   search: m[0]=get
get_XY, get|get_X:
   search: m[0]=get
get_X, get.*:
   match : m[0]=get_X
   search: m[0]=get_X
```

std::smatch の詳細

- m.size(), m.empty() でマッチしたかを確認可能
- prefix() マッチする前の文字列, suffix() 後の文字列
- m[0] マッチ全体, m[n] グループ化した部分
- m.position(n) グループ n の元文字列の位置

```
string data { "abc<h1>title</h1>xyz" };
cout <<"data: " << data <<"\n";
std::regex r{ R"(<([\w]+)>(.*)</(\1)>)" };
std::smatch m;
std::regex_search(data, m, r);
if (!m.empty()) {
    cout <<"m.prefix():"<< m.prefix()<<"\n"
         <<"m.suffix():"<< m.suffix()<<"\n";
    for (size_t i = 0; i < m.size(); i++) {
        cout <<"m["<< i <<"]:"<< m[i] <<", "
             <<"m.position("<< i <<"):"
             << m.position(i) <<"\n";
    }
}  // string を得るには.str()
```

正規表現の確認

正規表現： `<([\w]+)>(.*)</(\1)>`

- `<([\w]+)>`
  - 開きタグに対応
  - `<`で始まり，1 文字以上の英数文字，`>`が続く
  - 1 文字以上の英数字がマッチしたら記憶（番号 1）
- `(.*)`
  - 0 文字以上の改行以外の文字
  - これもマッチしたら記憶（番号 2）
- `</(\1)>`
  - 閉じタグに対応
  - `</`の文字列，番号 1 で記憶した文字列，`>`の文字
  - これもマッチしたら記憶（番号 3）

出力結果

- position は文字列 data の添字に対応する

```
data: abc<h1>title</h1>xyz
m.prefix():abc
m.suffix():xyz
m[0]:<h1>title</h1>, m.position(0):3
m[1]:h1, m.position(1):4
m[2]:title, m.position(2):7
m[3]:h1, m.position(3):14
```

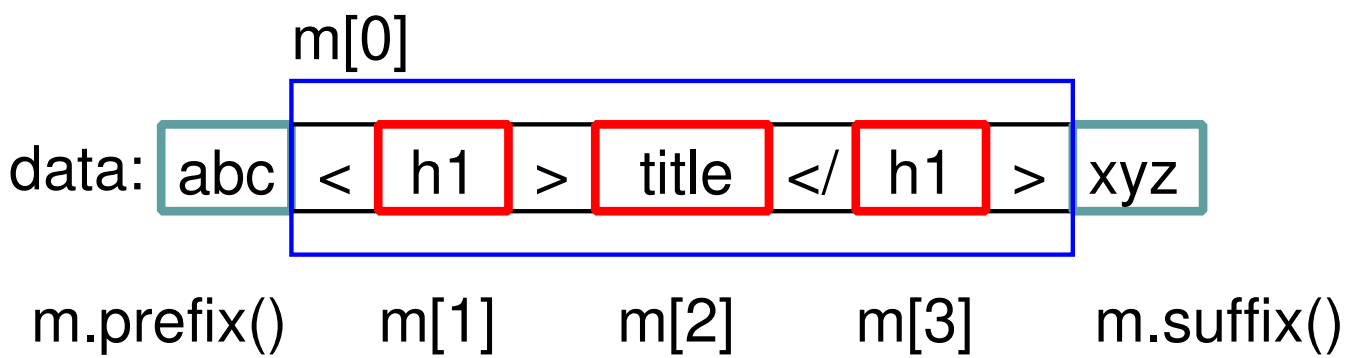

string イテレータの利用

- cbegin(), cend() は const イテレータ
- m.suffix().first はマッチの次の文字のイテレータ

```
string d {R"(
<student>
<first>Momoko</first>
<last>Seikei</last>
</student>)" }; // 改行を含む文字列
cout << d <<"\n";
std::regex r{R"(<([\w]*)>(.*)</\1>)"};
auto pos { d.cbegin() };
auto end { d.cend()   };
std::smatch m;
for ( ; std::regex_search(pos, end, m, r);
        pos = m.suffix().first) {
   cout <<"------------\n"
        <<"match: "<< m[0].str() <<"\n" // m[0] も OK
        <<"tag:   "<< m[1].str() <<"\n"
        <<"value: "<< m[2].str() <<"\n";
}
```

出力結果

- `regex_search()` は改行を除き最大一致をとる
- 元の文字列に改行がなければ `student` のみマッチ

```
   <student>
   <first>Momoko</first>
   <last>Seikei</last>
   </student>
------------
match: <first>Momoko</first>
tag:   first
value: Momoko
------------
match: <last>Seikei</last>
tag:   last
value: Seikei
```

データに改行がない場合

- 改行のない対象文字列では全体がマッチする

```
<A><B>Momoko</B><C>Seikei</C></A>
------------
match: <A><B>Momoko</B><C>Seikei</C></A>
tag:   A
value: <B>Momoko</B><C>Seikei</C>
```

- 正規表現の変更で対応可能:`<([\w]*)>([^<]*)</\1>`

```
<A><B>Momoko</B><C>Seikei</C></A>
------------
match: <B>Momoko</B>
tag:   B
value: Momoko
------------
match: <C>Seikei</C>
tag:   C
value: Seikei
```

smatch 用イテレータの利用

- 内部で std::regex_search() を呼ぶ
- イテレータは std::smatch を指している
- プログラムが少し短くなる

```
string d{"<A><B>Momoko</B><C>Seikei</C></A>"};
std::regex r{R"(<([\w]*)>([^<]*)</\1>)"};
std::sregex_iterator pos{d.cbegin(), d.cend(), r};
std::sregex_iterator end;
for ( ; pos != end; ++pos){
    auto m{*pos}; // std::smatch
    cout <<"------------\n"
         <<"match: "<< m[0].str() <<"\n"
         <<"tag:   "<< m[1].str() <<"\n"
         <<"value: "<< m[2].str() <<"\n";
}
```

置き換え:std::regex_replace

- $1, $2 はグループ化文字列

```
string d {R"(<A><B>Momoko</B><C>Seikei</C></A>)"};
cout << d <<"\n";
std::regex before{R"(<([\w]*)>([^<]*)</\1>)"};
string     after {"<$1 val=\"$2\"/>"};
string rst1, rst2;

// 関数の戻り値
rst1 = std::regex_replace(d, before, after);
cout << rst1 <<"\n";

// 範囲を明示して 1 文字ずつ rst2 へ
std::regex_replace(std::back_inserter(rst2),
       d.cbegin(), d.cend(), before, after);
cout << rst2 <<"\n";
```

出力結果

- 結果はどちらも同じ
- XML/HTML の記法
  - <tag />は閉じタグを省略する書き方
  - <tag attrib="1"/>は attrib という属性値の指定
    - 属性が複数ある場合にはスペース文字で区切って並べる

```
<A><B>Momoko</B><C>Seikei</C></A>
<A><B val="Momoko"/><C val="Seikei"/></A>
<A><B val="Momoko"/><C val="Seikei"/></A>
```

トークンの取得:std::sregex_token_iterator

- 文字列（トークン）を取り出すイテレータ
- コンストラクタの引数
  - 第 1、2 で対象範囲, 第 3 に正規表現, 第 4 引数は下記
    - 0 マッチした文字列
    - -1 マッチしなかった文字列
    - n 正規表現内のグループ n の文字列

```
string t{"abc bcd cdef defgh ijk xyz"};
auto tb{t.cbegin()}, te{t.cend()};
std::regex r{R"(\w+)"};

std::sregex_token_iterator p{tb, te, r, 0};
std::sregex_token_iterator e;

for ( ; p != e; ++p) cout <<"\'"<< *p <<"\' ";
cout <<"\n";
// 'abc' 'bcd' 'cdef' 'defgh' 'ijk' 'xyz'
```

マッチしなかった文字列

- マッチしたパターンの間にある文字列を取り出せる
  - つまり、マッチしなかった文字列
- 区切り文字を正規表現で指定すれば残りが取り出せる

```
string t{"Hooray, it's nice! \n I like it."};
auto tb{t.cbegin()}, te{t.cend()};
std::regex sep{R"([.,?!\s]+)"}; // 注)

std::sregex_token_iterator p{tb, te, sep, -1}; // *
std::sregex_token_iterator e;

for ( ; p != e; ++p)
  cout <<"\'"<< *p <<"\' ";
cout <<"\n";
// 'Hooray' 'it's' 'nice' 'I' 'like' 'it'
```

注) 正規表現の [] の中では^-]\以外の文字は特殊な意味を持たない

グループ化文字列と複数指定

- 第 4 引数に 1 以上を指定するとグループ化した文字列
- 複数の場合には波括弧でリストを指定する
  - {1,2}: 部分文字列のグループ 1 と 2
  - {0,1}: 全体文字列と部分文字列のグループ 1

```
string t{R"(<A><B>Momoko</B><C>Seikei</C></A>)"};
auto tb{t.cbegin()}, te{t.cend()};
std::regex tag{R"(<([\w]*)>([^<]*)</\1>)"};

std::sregex_token_iterator p{tb, te, tag, {0,1}};
std::sregex_token_iterator e;

for ( ; p != e; ++p)
  cout <<"\'"<< *p <<"\' ";
cout <<"\n";
// '<B>Momoko</B>' 'B' '<C>Seikei</C>' 'C'
```

日本語の扱いについて

正確に書くと長くなるので大雑把に

日本語処理は難しい

- `char` 型は通常 8 ビットで英数記号の文字用
- `std::string` は `char` 型データの並びを扱う
- ひらがなと漢字を表すには 8 ビットでは足りない
- 文字集合とその符号化はそれぞれ複数ある
  - 文字集合とは文字に対する数値の表
  - 符号化とは文字の数値を具体的なビット列にする方法
- 現状の日本語の符号化の主流も複数
  - Shift JIS(の変種)、UTF-8, UTF-16, ...
- C++ではそれらの符号化を直接サポートしない
  - 日本語のプログラムはたいてい環境/OS 依存
  - 変換のライブラリも。。。
  - `std::string` で日本語が扱えても環境/OS 依存

```
文字「あ」のコード例
Shift JIS: |0x82|0xA0|
UTF-8    : |0xE3|0x81|0x82|
UTF-16   : |0x30|0x42|
```

日本語文字列と正規表現

- `std::regex`, `std::smatch` は `std::string` で使える
- 正規表現で日本語の文字列を表すには...
  - `wchar_t`:ワイド文字用のデータ型を基本に、
  - `std::wregex`, `std::wsmach`, `std::wstring` を使う
  - 入出力には設定変更（ロケール）が必要
    （または文字コードの変換）
  - ただ、正規表現でどれくらい扱えるかはあやしい
    - 例 1:`.`（ドット）：いわゆる全角文字にもマッチする
    - 例 2:`\d`：いわゆる全角の１２３にはマッチしない
- 正規表現で ASCII の範囲のみ扱うならばなんとかなる
  - 入出力の文字コードは確認／変換が必要
  - 日本語の文字列部分を変更しない
  - 例：「`<t1>`ラベル`</t1>`」ならば処理できることが多い